


Rendimiento y Hardware

Conceptos Clave de Arquitectura de Computadores



1. ¿Qué es el Desempeño?

Concepto Base

El desempeño es qué tan "bien" realiza su trabajo un computador. En arquitectura, se define como el inverso del tiempo de ejecución.

A mayor velocidad de ejecución, mejor es el rendimiento del sistema.

$$\text{Desempeño} = 1 / \text{Tiempo}$$

→ *Menos tiempo = Más desempeño*

2. Latencia y Throughput



Latencia (Tiempo)

Tiempo que tarda una sola tarea de principio a fin.

Ejemplo: ¿Cuánto tarda una instrucción en salir de la CPU?

Se mide en nanosegundos (ns) o microsegundos (μ s).



Throughput (Productividad)

Cantidad de trabajo completado por unidad de tiempo.

Ejemplo: ¿Cuántas instrucciones se terminan por segundo?

Se puede aumentar con paralelismo sin reducir la latencia.


3. El Tiempo de Ejecución

Es la métrica más importante. Depende de tres factores fundamentales:



Cantidad de Instrucciones

Total de instrucciones que ejecuta el programa



Ciclos por Instrucción (CPI)

Promedio de ciclos de reloj que necesita cada instrucción



Tiempo del Ciclo de Reloj

Duración de cada ciclo, inversamente proporcional a la frecuencia

$$\text{Tiempo CPU} = \text{Instrucciones} \times \text{CPI} \times T_{\text{Reloj}}$$

4. Aceleración (Speedup)

Nos dice cuántas veces es más rápido un computador mejorado frente al original.

Un Speedup > 1 indica mejora; un Speedup < 1 indica degradación.

$$\text{Speedup} = \text{Tiempo_viejo} / \text{Tiempo_nuevo}$$

Si el Speedup es 2, el nuevo computador es el doble de rápido.

Si el Speedup es 0.5, el nuevo sistema es el doble de lento.

Original

10s

Mejorado (2x)

5s

Speedup = 2.0x
Doble de rápido

5. La Ley de Amdahl

Establece que la mejora total de un sistema está limitada por la parte que no se puede mejorar.

Por eso, es más eficiente optimizar las secciones que más se ejecutan.

$$\text{Speedup_max} = 1 / (1 - p)$$

donde p = fracción paralelizable del programa

"No importa cuántos procesadores pongas, si el 10% del programa es secuencial, nunca serás más de 10 veces más rápido."

Regla de Oro: Haz que el caso común sea rápido.


6. Bandwidth

Es la capacidad máxima de un canal para mover datos. Se mide en Bits por segundo (bps) o Gigabytes por segundo (GB/s).

En arquitectura, es crítico en el Bus de Memoria: qué tan rápido puede la RAM enviar datos al procesador.

Un procesador muy rápido puede quedar limitado si el ancho de banda de memoria es bajo — a esto se le llama cuello de botella de memoria.

Ejemplo: DDR5 ofrece hasta 76.8 GB/s por canal



7. Throughput en Arquitectura

Es la tasa real de éxito en completar instrucciones.



MIPS — Millones de instrucciones por segundo

Métrica para instrucciones de enteros y control.



FLOPS — Operaciones de punto flotante por segundo

Esencial en cómputo científico, IA y gráficos 3D.

El Pipeline

Funciona como una cadena de montaje. Aunque cada instrucción sigue tardando lo mismo en completarse (latencia), al solapar etapas se logra terminar más instrucciones por segundo (throughput).

Ejemplo: Un pipeline de 5 etapas puede completar 1 instrucción por ciclo en estado estable.

Analogía: Latencia vs Throughput



Lavar 1 carga: 30 min

(Latencia)

Tiempo desde que empieza hasta que termina una sola carga.



4 cargas por hora

(Throughput)

Con 4 lavadoras en paralelo: misma latencia, 4x más trabajo por hora.

Resumen de Métricas



Tiempo

Mide segundos por tarea



Desempeño

Mide tareas por segundo ($= 1 / \text{Tiempo}$)




Bandwidth

Capacidad máxima de transporte de datos



Speedup

$\text{Tiempo_viejo} / \text{Tiempo_nuevo}$ — cuánto mejoró



MIPS / FLOPS

Throughput real: instrucciones u operaciones por segundo