

UNIVERSIDAD DE LAS FUERZAS ARMADAS

ESPE

DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN

INVESTIGACIÓN EN INGENIERÍA DE SOFTWARE



1922
ECUADOR

ESPE

UNIVERSIDAD DE LAS FUERZAS ARMADAS
INNOVACIÓN PARA LA EXCELENCIA

INGENIERÍA DE SOFTWARE

Integrantes: Josue Chango

Docente: Ángel Marcelo Rea Guamán

NRC: 30821

Fecha: 14 de julio de 2026

Fases de un Experimento en Ingeniería de Software

Experimento: Experimentación en ingeniería de software: Caso de estudio programación en pareja

Contexto

Todo experimento en Ingeniería de Software puede organizarse en tres grandes fases: diseño y planificación, ejecución y recolección de datos, y reporte de resultados. Este documento esta basada en Ventura Uscanga, J. J., Martínez Moreno, P., Morales Velázquez, L. A. y Vergara Camacho, J. A. (2025). *Experimentación en Ingeniería de Software: Caso de estudio programación en pareja*. Revista Perspectivas, 7(1). <https://doi.org/10.47187/perspectivas.7.1.239>

A continuación se desarrolla cada fase tomando como caso de estudio el experimento de programación en pareja realizado con estudiantes de la Licenciatura en Ingeniería de Software de la Universidad Veracruzana, Campus Coatzacoalcos.

Fase 1: Diseño y Planificación

Esta es la etapa en la que el equipo investigador decide qué quiere estudiar, por qué vale la pena hacerlo y cómo va a llevar a cabo el experimento, todo esto antes de tener contacto con los sujetos. Aquí entra la motivación del estudio, la pregunta de investigación, la selección de los participantes, las variables que se van a medir y los instrumentos que se usarán para recolectar los datos.

1.1 Motivación y contexto

La programación en pareja consiste en que dos personas trabajen juntas frente a una misma computadora: una hace de conductor (driver) y escribe el código, mientras la otra hace de navegador (navigator) y va revisando ese trabajo para detectar errores que puede cometer el conductor, como fallas de sintaxis, de ortografía o llamadas a la función equivocada, que son decisiones de diseño que se alejan de lo que la función debería lograr realmente. Varios autores han documentado los beneficios de esta práctica: mejora la calidad del código, acelera su producción, genera más confianza entre los programadores y ayuda a que el conocimiento se transfiera entre compañeros.

El estudio se hizo en un contexto particular: la región de Coatzacoalcos, donde hay pocas empresas de desarrollo de software. Justamente por eso los docentes de Ingeniería de Software de la zona buscaban métodos de enseñanza que realmente fortalezcan las competencias de programación de sus estudiantes.

1.2 Objetivo y pregunta de investigación

El objetivo del experimento era: averiguar si la programación en pareja mejora el aprendizaje, el rendimiento académico y la calidad del trabajo de los estudiantes de Ingeniería de Software, comparada con programar de forma individual.

De ahí salieron las hipótesis de trabajo, que más adelante se pusieron a prueba con estadística:

- H0: la diferencia entre las medianas de los puntajes obtenidos en pareja y de forma individual es menor o igual a cero, es decir, no hay mejora.
- H1: la diferencia entre las medianas de los puntajes obtenidos en pareja y de forma individual es mayor a cero, es decir, sí hay mejora al trabajar en pareja.

1.3 Selección de sujetos

Participaron 15 estudiantes de quinto periodo de la Licenciatura en Ingeniería de Software, en la materia de Paradigmas de Programación, durante el bloque de programación orientada a objetos (POO). Todos venían con una base sólida: ya habían cursado Introducción a la Programación, Programación, Estructuras de Datos y Principios de

Construcción de Software. Desde el diseño quedó claro que 15 estudiantes es una muestra pequeña, así que se decidió usar desde un inicio pruebas estadísticas pensadas para ese tamaño de muestra.

1.4 Selección de variables

Se definieron dos tipos de variables:

- Variable independiente: la estrategia o estilo de programación aplicado en cada actividad, es decir, programación individual frente a programación en pareja.
- Variables dependientes: la calificación obtenida, sobre 100 puntos, y el puntaje de calidad del código, sobre 36 puntos, ambas usadas para medir el desempeño de los estudiantes.

1.5 Instrumentación

Se diseñaron dos actividades ligadas al paradigma de POO. La primera era individual y trataba de construir una aplicación para controlar un registro de vehículos. La segunda se hacía en pareja y pedía una aplicación de complejidad similar, pero para gestionar una biblioteca. En ambas se ponían en práctica los mismos conceptos: clases y sus relaciones, herencia y encapsulación.

Para evaluar el trabajo se usaron dos rúbricas. Una servía para asignar la calificación general, sobre 100 puntos. La otra medía específicamente la calidad del código: dominio del lenguaje Java, fundamentos de POO, claridad y mantenibilidad, uso de patrones de diseño, documentación y comentarios, optimización del rendimiento, manejo de recursos, y resolución de problemas y depuración, hasta sumar 36 puntos.

Fase 2: Ejecución y Recolección de Datos

Aquí es donde todo lo planificado se pone en práctica: los sujetos entran en contacto con el experimento, se aplican los tratamientos definidos y los datos que resultan se recolectan y se depuran.

2.1 Ejecución del experimento

Antes de empezar, se les explicó brevemente a los estudiantes que iban a participar en un experimento sobre programación en pareja, incluyendo cómo funciona la dinámica de conductor y navegador. Las dos actividades se hicieron en sesiones distintas, dentro de un laboratorio de cómputo, acomodando a los estudiantes de manera que el trabajo en pareja fuera cómodo. También se les pidió mantener buenas prácticas de codificación y documentación. Al terminar cada actividad, entregaban sus evidencias en un repositorio de GitHub.

2.2 Validación de datos

Ya con las calificaciones y los puntajes de calidad de código ya a la mano, aparecieron dos valores fuera de los comunes, de los mismos estudiantes, en la actividad individual. Con una muestra tan pequeña, esos dos valores cambiaban bastante la distribución de los datos. Por otro lado, se dejó fuera el resultado de un estudiante en la actividad en pareja, para que ambos grupos quedaran con el mismo número de casos y el análisis posterior fuera más parejo.

2.3 Datos recolectados

La tabla siguiente reúne los puntajes de cada estudiante, tanto en calificación como en calidad de código, en las dos modalidades:

Estudiante	Calificación		Calidad del código	
	Individual	Parejas	Individual	Parejas
1	65	90	32	33
2	90	95	31	32
3	35	70	10	24
4	85	90	18	32
5	45	70	14	24

6	90	90	30	33
7	85	90	34	32
8	90	95	32	34
9	90	90	34	32
10	85	90	30	33
11	95	95	31	33
12	75	90	24	33
13	70	90	24	32
14	35	90	15	33
15	85	95	29	34

Fase 3: Reporte de Resultados

En esta última fase se analizan los datos, se ponen a prueba las hipótesis planteadas desde el diseño, se revisan las amenazas a la validez del experimento y se escriben las conclusiones.

3.1 Estadística descriptiva

El promedio de calificaciones fue de 74.67 (mediana 85, $s = 20.57$) trabajando de forma individual, contra 88.67 (mediana 90, $s = 7.90$) en pareja. Con la calidad de código pasó algo parecido: 25.87 en promedio (mediana 30, $s = 7.95$) individual, frente a 31.60 (mediana 33, $s = 3.16$) en pareja. Vale la pena notar que la desviación estándar bajó bastante en la modalidad de pareja, señal de que los resultados fueron más parejos entre estudiantes y menos dispersos respecto al promedio.

3.2 Análisis de normalidad

Antes de elegir la prueba de contraste de hipótesis, se corrió la prueba de Shapiro-Wilk ($\alpha = 0.05$) para ver si los datos seguían una distribución normal:

Origen	α	W	p	¿Rechaza H0?
Calificación individual	0.05	0.794	0.003	Sí ($0.003 < 0.05$)
Calificación en pareja	0.05	0.623	4.201e-05	Sí ($4.201e-05 < 0.05$)
Calidad individual	0.05	0.852	0.018	Sí ($0.018 < 0.05$)
Calidad en pareja	0.05	0.601	2.624e-05	Sí ($2.624e-05 < 0.05$)

En los cuatro casos se rechazó la normalidad. Eso llevó a usar una prueba no paramétrica: la de rangos con signo de Wilcoxon para muestras dependientes, de cola superior, que tiene sentido aquí porque se trata de los mismos estudiantes evaluados antes y después de programar en pareja.

3.3 Comparación de resultados

Los resultados de la prueba de Wilcoxon para ambas variables dependientes se resumen a continuación:

Variable	V	p	¿Rechaza H0?
Calificaciones	0	0.001	Sí ($0.001 < 0.05$)
Calidad del código	9	0.002	Sí ($0.002 < 0.05$)

Con $\alpha = 0.05$, el valor p en calificaciones (0.001) y en calidad del código (0.002) permitió rechazar la hipótesis nula en los dos casos. En otras palabras, trabajar en pareja dio puntajes con una mediana estadísticamente más alta que trabajar solo, tanto en calificación como en calidad de código.

3.4 Amenazas a la validez

Validez interna. Aquí entran tres amenazas posibles. Primero, los estudiantes se emparejaron libremente, y eso pudo afectar los resultados para bien o para mal. Segundo, la experiencia que ganaron en la primera actividad seguramente les ayudó en la segunda. Y tercero, saber que estaban siendo evaluados pudo cambiar su nivel de esfuerzo de una actividad a otra.

Validez externa. La principal amenaza aquí fue la selección de sujetos, pero se consideró aceptable porque tanto el contexto como el perfil de los estudiantes encajaban con el público al que apunta el estudio.

Validez de la conclusión. Con una muestra tan chica, el poder estadístico de la prueba quedó limitado, y por eso se usó Wilcoxon en vez de la prueba T pareada. Esta última tiene más poder estadístico, pero exige que los datos sean normales, algo que aquí no se cumplió.

3.5 Conclusiones

El análisis estadístico deja una conclusión clara: la programación en pareja funciona como estrategia de enseñanza en Ingeniería de Software, con un impacto positivo tanto en el rendimiento académico como en la calidad del código. Trabajando en pareja, el promedio de calificaciones subió, el código cumplió mejor con los criterios de calidad, y los resultados variaron menos entre estudiantes. Esto coincide con lo que ya se había encontrado en otros contextos, como China en 2010 y Nueva Zelanda en 2013, aunque en la región de Coatzacoalcos este experimento no se había hecho antes.